

# 偏最小二乘回归分析(Partial Least Squares Regression, PLS)

- 当研究两组多重相关变量间的相互依赖关系，并研究用一组变量去预测另一组变量时使用。
- 当两组变量个数很多且都存在多重相关性，而观测数据的数量又较少时，使用PLS建立模型较优。
- 计算过程
  - 分别提取两变量组的第一对成分 $u_1, v_1$ 并使之相关性达到最大,其中 $u_1, v_1$ 分别是数据集 $X = (x_1, x_2, \dots, x_m)^T$ 和指标集 $Y = (y_1, y_2, \dots, y_p)^T$ 的线性组合。要求 $u_1, v_1$ 各自尽可能多地提取所在变量组的变异信息且相关程度达到最大。
  - 由 $u_1 = \rho^{(1)T} X$ 和 $v_1 = \gamma^{(1)T} Y$ 和两变量组的标准化观测数据矩阵 $A$ 和 $B$ 计算第一对成分的得分向量，记为 $\hat{u}_1, \hat{v}_1$

$$\begin{aligned}\hat{u}_1 &= A\rho^{(1)} = \begin{pmatrix} a_{11} & \cdots & a_{1m} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nm} \end{pmatrix} \begin{pmatrix} \alpha_{11} \\ \vdots \\ \alpha_{1m} \end{pmatrix} \\ \hat{v}_1 &= B\gamma^{(1)} = \begin{pmatrix} b_{11} & \cdots & b_{1m} \\ \vdots & \ddots & \vdots \\ b_{n1} & \cdots & b_{nm} \end{pmatrix} \begin{pmatrix} \beta_{11} \\ \vdots \\ \beta_{1m} \end{pmatrix}\end{aligned}$$

- 建立 $y_1, y_2, \dots, y_p$ 对 $u_1$ 的回归及 $x_1, x_2, \dots, x_m$ 对 $u_1$ 的回归。假定回归模型为

$$\begin{cases} A = \hat{u}_1 p^{(1)T} + A_1 \\ B = \hat{u}_1 q^{(1)T} + B_1 \end{cases}$$

其中 $p^{(1)} = (p_{11}, p_{12}, \dots, p_{1m})^T$ ,  $q^{(1)} = (q_{11}, q_{12}, \dots, q_{1p})^T$ 分别为多对一的回归模型中的参数向量; $A_1$ 和 $B_1$ 是残差阵

- 回归系数向量 $p^{(1)}, q^{(1)}$ 的最小二乘估计为

$$\begin{cases} p^{(1)} = A^T \hat{u}_1 / u_1^T \hat{u}_1 \\ q^{(1)} = B^T \hat{u}_1 / u_1^T \hat{u}_1 \end{cases}$$

称 $p^{(1)}, q^{(1)}$ 为模型效应负荷量

- 用残差阵 $A_1, B_1$ 代替 $A, B$ 重复上述步骤。记 $\hat{A} = \hat{u}_1 p^{(1)T}$ ,  $\hat{B} = \hat{u}_1 q^{(1)T}$ ，则残差为 $A_1 = A - \hat{A}$ ,  $B_1 = B - \hat{B}$ 。如果残差阵 $B_1$ 中元素的绝对值近似为0，则可认为用第一个成分建立

的回归式精度已满足需要了，可以停止抽取成分。否则利用残差阵 $A_1, B_1$ 代表 $A, B$ 重复上述步骤。直到重复预定次数 $k$ 或残差很小，解释的方差比例达到要求。

- 最终回归系数公式

$$B = W(P^T W)^{-1} Q^T$$

假设提取了 $k$ 个潜变量，这里

$$\begin{cases} W = (w_1, w_2, \dots, w_k) \\ P = (p_1, p_2, \dots, p_k) \\ Q = (q_1, q_2, \dots, q_k) \end{cases}$$

其中 $W$ 为 $X$ 的权重向量,  $w_i = \frac{(X^{(i-1)})^T u_i}{\|(X^{(i-1)})^T u_i\|}$

预测  $\hat{Y} = XB$ ，如果加截距，要先对 $X, Y$ 中心化并记录均值，预测时再加回去

## 误差平方和(Sum of Square Error, SSE)

- 对某个模型来说，误差平方和就是预测值和实际值之差的平方和：

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 多响应变量(矩阵 $Y$ )，通常是对每个响应变量分别算，再求和

$$SSE_j = \sum_{i=1}^n (y_{ij} - \hat{y}_{ij})^2$$

## 预测误差平方和(Partial Sun of Squares, PRESS)

- PRESS是一种衡量预测能力的指标，通过留一法(Leave-One-Out)或 $k$ 折交叉验证得到的预测误差平方和：

$$PRESS = \sum_{i=1}^n (y_i - \hat{y}_{i,(-i)})^2$$

这里 $\hat{y}_{i,(-i)}$ 是在去掉第 $i$ 个样本后用剩下数据建模，在预测第 $i$ 个样本的值。

# 交叉有效性验证(Cross-Validation,CV)

- 交叉有效性验证就是用交叉验证的方式来检验 PLS 模型的稳定性和预测能力。
- 常见形式
  - 留一法 (LOOCV): 每次留一个样本作为验证集, 其余作为训练集。
  - K 折交叉验证: 将数据随机分成 K 份, 每次用其中 1 份验证, 其余 (K-1) 份训练, 循环 K 次。
- 在PLS回归中的作用
  - 用来决定最佳成分数  $k$ :  
通过比较不同成分数的 PRESS 值, 选择 PRESS 最小 (或接近最小) 的那个成分数, 避免过拟合。
- 计算交叉验证相关系数  $Q^2$ :

$$Q^2 = 1 - \frac{PRESS}{SSY}$$

其中  $SSY$  为  $Y$  的总平方和(总变异),  $Q^2$  越接近 1, 说明预测能力越好

## MATLAB代码

- `[XL,YL,XS,YS,BETA,PCTVAR,MSE,STATS]=plsregress(X,Y,ncomp)`
  - $X$  为  $n \times m$  的自变量数据矩阵。 $Y$  为  $n \times p$  的因变量数据矩阵。 $ncomp$  为成分的个数。
  - $XL$  为对应于  $p^{(i)}$  的  $m \times ncomp$  的负荷量矩阵;  $YL$  为对应于  $q^{(i)}$  的  $p \times ncomp$  矩阵。
  - $XS$  为对应于  $\hat{u}_i$  的得分矩阵,  $YS$  为对应于  $\hat{v}_i$  的得分矩阵。
  - $BETA$  为每列对应于回归表达式的系数矩阵:

$$y_j = c_{j1}x_1 + c_{j2}x_2 + \cdots + c_{jm}x_m, j = 1, 2, \cdots, p$$

- $PCTVAR$  为贡献率矩阵, 第一行为每个元素对应自变量提出成分的贡献率, 第二行为每个元素对应自变量提出成分的贡献率。
  - $MSE$  为标准差矩阵。
  - $STATS$  返回四个值, 其中,  $STATS.W$  每列对应特征值  $\rho^{(i)}$ 。
- 根据结果画图:
  - 得到的  $BETA$  是回归方程系数矩阵, 每一列对应一个因变量, 第一行为常系数
  - 方程写法为:  $\hat{Y} = \beta_0 + X\beta$
  - 用 `ones(size(X,1),1)*beta(1,:)+X*BETA(2:end,:)` 算出预测值, 但此时得到的是标准化后的预测值
  - 反标准化:

$$\begin{cases} Y_{std} = \beta_{0,std} + X_{std}\beta_{std} \\ Y = \mu_Y + \sigma_Y \cdot (\beta_{0,std} + \frac{X - \mu_X}{\sigma_X} \beta_{std}) \end{cases}$$

- 原始尺度回归系数为

$$\begin{cases} \beta = \frac{\sigma_Y}{\sigma_X} \cdot \beta_{std} \\ \beta_0 = \mu_Y + \sigma_Y \cdot \beta_{0,std} - \mu_X \cdot \beta \end{cases}$$

- 此时即可得到为标准化下的预测方程：

$$\hat{Y} = \beta_0 + X\beta$$

- 在MATLAB中写法为：  
`b=(sigmay./sigmax').*BETA2(2:end,:);%系数`  
`b0=muy+sigmay.*BETA2(1,:)-mux*b;%截距, Y_pred=ones(size(x,1),1)*b0+x*b;%预测值`