

多元分析

主成分分析

对于 n 个样本 m 项指标,希望使用较少的变量解释原资料中的大部分变异,即将原本相关性很高的变量转换成彼此相互独立或不相关的变量。通常选出比原始变量个数少的,能解释大部分资料的变异的几个新变量,即所谓的主成分,以此解释资料的综合性指标,本质上主成分分析是一种降维方法。

具体步骤:

- 原数据标准化:

$$\tilde{x}_{ij} = \left(\frac{x_{ij} - \mu_i}{\sigma_i} \right)$$

- μ_i 为平均值, σ_i 为标准差,标准化是为了解决数据量纲和初始相差方差过大的问题,得到表转化数据矩阵 $\tilde{A}$ 。
- 计算相关系数矩阵 $R = \tilde{A}^T \tilde{A} / (n - 1)$
- 计算相关系数矩阵的特征值和特征向量(单位正交)
- 选取特征值最大的几个作为主成分,注意特征值信息贡献率和累计贡献率都要求较大,符合要求。
- 构建主成分:

$$z_i = c_{i1}X_1 + c_{i2}X_2 + \cdots + c_{ip}X_p$$

z_i 是第 i 个主成分, $c = (c_{i1}, c_{i2}, \cdots, c_{ip})$ 为对应特征值的正交单位特征向量

- matlab代码:
 - `zscore()`%对矩阵进行标准化处理
 - `corrcoef()`%计算相关系数矩阵
 - `[vec,lambda,rate]=pcacov(R)`%针对相关系数矩阵 R , vec 为 R 的特征向量, $lambda$ 为 R 的特征值, $rate$ 为各个主成分的贡献率

因子分析

- 因子分析中将可观测数据分解为公共因子、特殊因子、和误差三部分。
- 因子是抽象的、无法直接测得的
- 因子分析关键在于估计因子载荷、方差,并给出因子的合理解释,如果解释困难,需要进行因子旋转。
- 数学模型;
 - 设 p 个变量 $X_i, (i = 1, 2, \cdots, p)$ 可以表示为:

$$X_i = \mu_i + \alpha_{i1}F_1 + \cdots + \alpha_{im}F_m + F_m + \varepsilon_i, m \leq p$$

或：

$$\begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{pmatrix} + \begin{pmatrix} \alpha_{11} & \alpha_{12} & \cdots & \alpha_{1m} \\ \alpha_{21} & \alpha_{22} & \cdots & \alpha_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{p1} & \alpha_{p2} & \cdots & \alpha_{pm} \end{pmatrix} \begin{pmatrix} F_1 \\ F_2 \\ \vdots \\ F_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_p \end{pmatrix}$$

或

$$X - \mu = \Lambda F + \varepsilon$$

$F_1, F_2, \dots, F_p$ 为公共因子，是不可观测的变量，其系数为载荷因子。 ε_i 是特殊因子，是不能被前 m 个公共因子包含的部分，且满足

$$E(F) = 0, E(\varepsilon) = 0, Cov(F) = I_m, D(\varepsilon) = Cov(\varepsilon) = diag(\sigma_1^2, \sigma_2^2, \dots, \sigma_m^2), Cov(F, \varepsilon) = 0$$

• 因子载荷矩阵中几个统计意义

- 因子载荷 α_{ij} : 因子载荷 α_{ij} 是第 i 个变量与第 j 个公共因子的相关系数, 反应第 i 个变量与第 j 个公共因子的相关重要性。绝对值越大, 相关的密切程度越高。
- 变量 X_i 的共同度: 因子载荷矩阵的第 i 行的元素的平方和, 记为 $h_i^2 = \sum_{j=1}^m \alpha_{ij}^2$

由

$$Var(X_i) = \alpha_{i1}^2 Var(F_1) + \cdots + \alpha_{im}^2 Var(F_m) + Var(\varepsilon_i)$$

即得

$$1 = \sum_{j=1}^m \alpha_{ij}^2 + \sigma_i^2 = h_i^2 + \sigma_i^2$$

式中特殊因子得方差为 $\sigma_i^2 (i = 1, 2, \dots, p)$ 称为特殊方差

- 可见所有公共因子和特殊因子对变量 X_i 的贡献为 1. 如果 $\sum_{j=1}^m \alpha_{ij}^2$ 非常接近 1, σ_i^2 非常小, 则因子分析的效果好, 从原变量到公共因子空间的转换效果好。
- 因子载荷矩阵各列元素的平方和

$$S_j = \sum_{i=1}^p \alpha_{ij}^2$$

称为 $F_j (j = 1, 2, \dots, m)$ 对于所有 X_i 的方差贡献和, 用于衡量 F_j 的相对重要性。

- 因子分析中的基本问题在于如何估计载荷因子矩阵, 即如何求解因子模型

求解

主成分分析法

- 设 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ 为样本相关系数矩阵 R 的特征值， $\eta_1, \eta_2, \dots, \eta_p$ 为相应的标准正交化特征向量。设 $m < p$ ，则因子载荷矩阵为：

$$\Lambda = (\sqrt{\lambda_1}\eta_1, \sqrt{\lambda_2}\eta_2, \dots, \sqrt{\lambda_p}\eta_p)$$

特殊因子方差用 $R - \Lambda\Lambda^T$ 来估计

$$\sigma_i^2 = 1 - \sum_{j=1}^m \alpha_{ij}^2 = 1 - h_i^2$$

主因子法

- 主因子法是对主成分法的修正，假定对变量进行了标准化变换，则

$$R = \Lambda\Lambda^T + D$$

$$D = \text{diag}\{\sigma_1^2, \sigma_2^2, \dots, \sigma_m^2\}$$

记

$$R^* = \Lambda\Lambda^T = R - D$$

该式中 R^* 为相约关系矩阵， R^* 对角线上的元素是 h_i^2

- 实际问题中特殊因子的方差未知,可通过一组样本来估计，估计方法如下
 - 取 $\hat{h}_i^2 = 1$ ，这种情况下主因子解与主成分分解等价。
 - 取 $\hat{h}_i^2 = \max_{j \neq i} |r_{ij}|$,这意味着取 X_i 与其余 X_j 的简单相关系数的绝对值最大者

记

$$R^* = R - D = \begin{pmatrix} \hat{h}_1^2 & r_{12} & \cdots & r_{1p} \\ r_{21} & \hat{h}_2^2 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & \hat{h}_p^2 \end{pmatrix}$$

直接求 R^* 得的前 p 个特征值 $\lambda_1^* \geq \lambda_2^* \geq \dots \geq \lambda_p^*$,和对应的正交特征向量 $u_1^*, u_2^*, \dots, u_p^*$,得到载荷因子矩阵

$$\Lambda = (\sqrt{\lambda_1^*}u_1^*, \sqrt{\lambda_2^*}u_2^*, \dots, \sqrt{\lambda_p^*}u_p^*)$$

最大似然估计法

- 直接用matlab中的factoran实现

因子旋转

- 每个公共因子含义不清楚，不便于进行实际背景的解释。载荷因子矩阵不唯一，所以应对因子载荷矩阵进行旋转，使因子载荷矩阵结构简单化，使载荷矩阵每列或每行的元素平方值向0和1量及分化，主要方法有：方差最大法，四次方最大法和灯亮最大法。
- 使用matlab实现代码：
-[lambda2,t]=rotatefactors(lambda(1:num),'method','varimax') %lambda2为旋转后的载荷因子矩阵，t为变换的正交矩阵。lambda为原全部载荷因子矩阵，num为取多少个主因子，varimax为使用最大方差旋转

因子得分

- 因子分析模型给出了原变量表示为公共因子的线性组合，但通产情况下还想反过来把公共因子表示为原变量的线性组合。
- 因子得分函数

$$F_j = c_j + \beta_{j1}X_1 + \cdots + \beta_{jp}X_p, j = 1, 2, \cdots, p$$

- 因子得分实现关键在于得分矩阵的求解，由于 $p > m$ 该方程无法求得精确解，只能通过估计
- 常用方法有巴特莱特因子得分法(加权最小二乘法)、回归方法
 - 巴特莱特因子得分法：
 - 将 $X_i - \mu_i$ 看作因变量，因子载荷矩阵看作自变量的观测，由于特殊因子方差相异，用最小二乘法求得分，使

$$\sum_{i=1}^p [(X_i - \mu_i) - (\alpha_{i1}\hat{F}_1 + \alpha_{i2}\hat{F}_2 + \cdots + \alpha_{im}\hat{F}_m)]^2 / \sigma_i^2$$

最小的 $\hat{F}_1, \hat{F}_2, \cdots, \hat{F}_m$ 是相应的因子得分。

- 矩阵表达为

$$X - \mu = \Lambda F + \varepsilon$$

要使得

$$(X - \mu - \Lambda F)^T D^{-1} (X - \mu - \Lambda F)$$

达到最小，其中 $D = \text{diag}\{\sigma_1^2, \sigma_2^2, \cdots, \sigma_p^2\}$ ，上式取得最小值的 F 是相应的一因子得分

- 计算得

$$\hat{F} = (\Lambda^T D^{-1} \Lambda)^{-1} \Lambda^T D^{-1} (X - \mu)$$

◦ 回归方法

- 回归方法将公共因子视为因变量，原始变量视为自变量，通过最小二乘法(OLS)求解得分系数矩阵，使因子得分与原始变量误差最小。该方法不考虑特殊因子的影响(假设 $\varepsilon_i = 0$),计算简单
- 得到的因子得分估计为

$$\hat{F} = X_0 R^{-1} \Lambda$$

X_0 为原始数据矩阵， R 为原始变量的相关系数矩阵， Λ 为因子载荷矩阵

◦ matlab求解

- `[~,~,~,factor_score]=factoran(data,n_factors)` % data为原始数据矩阵，factor_scores为得分矩阵,fractoran为关键函数,n_factors为因子个数

判别分析

典型相关分析

一般研究量组变量

$$(x_1, x_2, \dots, x_p), (y_1, y_2, \dots, y_q)$$

的相关关系时，最原始的方法为分别计算量组变量之间的全部相关系数，一共有 pq 个简单相关系数,该方法繁琐而又无法抓住问题本质。借助主成分分析的思想，找出两组变量的线性组合作为新的变量，讨论新的变量(线性组合)之间的相关关系，可以达到简化问题、降低维度的目的。

- 分别在量组变量中找出第一对线性组合，使得其具有最大相关关系，即

$$\begin{cases} u_1 = \alpha_{11}x_1 + \alpha_{21}x_2 + \dots + \alpha_{p1}x_p, \\ v_1 = \beta_{11}y_1 + \beta_{21}y_2 + \dots + \beta_{q1}y_q \end{cases}$$

- 然后在每组变量中找出第二对线性组合，使其分别与本组内第一对线性组合不相关，第二对线性组合本身具有次大的相关性，有

$$\begin{cases} u_2 = \alpha_{21}x_1 + \alpha_{22}x_2 + \dots + \alpha_{p2}x_p, \\ v_2 = \beta_{21}y_1 + \beta_{22}y_2 + \dots + \beta_{q2}y_q \end{cases}$$

满足 u_1 与 u_2 ， v_1 与 v_2 不相关，但 u_2 与 v_2 相关。如此继续下去，直至到第 r 次两组变量的相关性被提取完为止，可以得到 r 组变量， $r \leq \min(p, q)$ 。

- 使用复相关系数(全相关系数)研究两组随机变量之间的相关关系。

- 复相关系数描述两组随机变量 $X = (x_1, x_2, \dots, x_p)^T$ 与 $Y = (y_1, y_2, \dots, y_p)^T$ 之间的相关程度，其思想为先将每一组随机变量作线性组合，成为两个随机变量

$$u = \rho^T X = \sum_{i=1}^p \rho_i x_i, v = \gamma^T Y = \sum_{i=1}^q \gamma_i y_i$$

再研究 u 与 v 的相关系数。由于 u, v 与投影向量 ρ, γ 有关，故 $r_{uv} = r_{uv}(\rho, \gamma)$ 。取在 $\rho^T \Sigma_{XX} \rho = 1$ 和 $\gamma^T \Sigma_{YY} \gamma = 1$ 的条件下使 r_{uv} 达到最大的 ρ, γ 作为投影向量，得到的相关系数即为复相关系数

$$r_{uv} = \max r_{uv}(\rho, \gamma)$$

- 两组协方差矩阵分块的得

$$\text{Cov} \begin{pmatrix} X \\ Y \end{pmatrix} = \begin{pmatrix} \text{Var}(X) & \text{Cov}(X, Y) \\ \text{Cov}(Y, X) & \text{Var}(Y) \end{pmatrix} = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}$$

得

$$r_{uv} = \frac{\text{Cov}(\rho^T X, \gamma^T Y)}{\sqrt{D(\rho^T X)} \sqrt{D(\gamma^T Y)}} = \frac{\rho^T \Sigma_{XY} \gamma}{\sqrt{\rho^T \Sigma_{XX} \rho} \sqrt{\gamma^T \Sigma_{YY} \gamma}} = \rho^T \Sigma_{XY} \gamma$$

- 问题转化为在 $\rho^T \Sigma_{XX} \rho = 1$ 和 $\gamma^T \Sigma_{YY} \gamma = 1$ 的条件下求 $\rho^T \Sigma_{XY} \gamma$ 的极大值
- 根据条件极值求法，引入拉格朗日乘数，问题转换为求

$$S(\rho, \gamma) = \rho^T \Sigma_{XY} \gamma - \frac{\lambda}{2} (\rho^T \Sigma_{XX} \rho - 1) - \frac{\omega}{2} (\gamma^T \Sigma_{YY} \gamma - 1)$$

的极大值， λ, ω 是拉格朗日乘数

- 结合极值必要条件有

$$\begin{cases} \frac{\partial S}{\partial \rho} = \Sigma_{XX} \gamma - \lambda \Sigma_{XX} \rho = 0 \\ \frac{\partial S}{\partial \gamma} = \Sigma_{YX} \rho - \omega \Sigma_{YY} \gamma = 0 \end{cases}$$

- 结合该必要条件可得

$$M_1 \rho = \lambda^2 \rho, M_2 \gamma = \lambda^2 \gamma$$

其中 $M_1 = \Sigma_{XX}^{-1} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$, $M_2 = \Sigma_{YY}^{-1} \Sigma_{YX} \Sigma_{XX}^{-1} \Sigma_{XY}$

- 以上说明 λ^2 既是 M_1 又是 M_2 的特征值， ρ, γ 就是其相应于 M_1 和 M_2 的特征向量。 M_1, M_2 的特征值非负且都在 $[0, 1]$ 上，非零特征值的个数等于 $\min(p, q)$ ，不妨设为 q 。
- 设 $M_1 \rho = \lambda^2 \rho$ 的特征值排序为 $\lambda_1^2 \geq \lambda_2^2 \geq \dots \geq \lambda_q^2$ ，其余 $p - q$ 个特征值为 0，称 $\lambda_1^2, \lambda_2^2, \dots, \lambda_q^2$ 为典型相关系数。相应的从 $M_1 \rho = \lambda^2 \rho$ 和 $M_2 \gamma = \lambda^2 \gamma$ 解出的特征向量 $\rho^{(1)}, \rho^{(2)}, \dots, \rho^{(q)}$ 和 $\gamma^{(1)}, \gamma^{(2)}, \dots, \gamma^{(q)}$ ，得

到 q 对线性组合

$$u_i = \rho^{(i)T} X, v_i = \gamma^{(i)T} Y, i = 1, 2, \dots, q$$

称每一对变量为典型变量。求典型相关系数和典型变量即为求 M_1, M_2 得特征值和特征向量。

- 还可证明, 当 $i \neq j$ 时, 有

$$\begin{cases} Cov(u_i, u_j) = Cov(\rho^{(i)T} X, \rho^{(j)T} X) = \rho^{(i)T} \Sigma_{XX} \rho^{(j)} = 0 \\ Cov(v_i, v_j) = Cov(\gamma^{(i)T} Y, \gamma^{(j)T} Y) = \gamma^{(i)T} \Sigma_{YY} \gamma^{(j)} = 0 \end{cases}$$

表明一切典型变量都是不相关的, 并且方差为1, 即

$$\begin{cases} Cov(u_i, u_j) = \delta_{ij} \\ Cov(v_i, v_j) = \delta_{ij} \end{cases}$$

其中

$$\delta_{ij} = \begin{cases} 1, i = j \\ 0, i \neq j \end{cases}$$

- X 与 Y 的同一对典型变量 u_i 和 v_i 之间的相关系数为 λ_i , 不同对的典型变量 u_i 和 $v_j (i \neq j)$ 之间也不相关, 也即协方差为0. 即

$$Cov(u_i, v_i) = \begin{cases} \lambda_i, i = j \\ 0, i \neq j \end{cases}$$

原始变量与典型变量之间的相关性

- 原始变量相关系数矩阵

$$R = \begin{pmatrix} R_{11} & R_{12} \\ R_{21} & R_{22} \end{pmatrix}$$

- X 典型变量相关系数矩阵

$$\Lambda = (\rho^{(1)}, \rho^{(2)}, \dots, \rho^{(s)})_{p \times s} = \begin{pmatrix} \alpha_{11} & \alpha_{12} & \cdots & \alpha_{1s} \\ \alpha_{21} & \alpha_{22} & \cdots & \alpha_{2s} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha_{p1} & \alpha_{p2} & \cdots & \alpha_{ps} \end{pmatrix}$$

- Y 典型变量系数矩阵

$$\Gamma = (\gamma^{(1)}, \gamma^{(2)}, \dots, \gamma^{(s)})_{q \times s} = \begin{pmatrix} \beta_{11} & \beta_{12} & \cdots & \beta_{1s} \\ \beta_{21} & \beta_{22} & \cdots & \beta_{2s} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{q1} & \beta_{q2} & \cdots & \beta_{qs} \end{pmatrix}$$

则有

$$Cov(x_i, u_j) = Cov(x_i, \sum_{k=1}^p \alpha_{kj} x_k) = \sum_{k=1}^p \alpha_{kj} Cov(x_i, x_k), j = 1, 2, \dots, s$$

x_i 与 u_j 的相关系数

$$r(x_i, u_j) = \sum_{k=1}^p \alpha_{kj} Cov(x_i, x_k) / \sqrt{D(x_i)}, j = 1, 2, \dots, s$$

同理有

$$r(x_i, v_j) = \sum_{k=1}^p \alpha_{kj} Cov(x_i, y_k) / \sqrt{D(x_i)}, j = 1, 2, \dots, s$$

$$r(y_i, u_j) = \sum_{k=1}^q \beta_{kj} Cov(y_i, x_k) / \sqrt{D(y_i)}, j = 1, 2, \dots, s$$

$$r(y_i, v_j) = \sum_{k=1}^q \beta_{kj} Cov(y_i, y_k) / \sqrt{D(y_i)}, j = 1, 2, \dots, s$$

- 各组原始变量被典型变量所解释的方差
 - X 组原始变量被 u_i 解释的方差比例为

$$m_{u_i} = \sum_{k=1}^p r^2(u_i, x_k) / p.$$

- X 组原始变量被 v_i 解释的方差比例为

$$m_{v_i} = \sum_{k=1}^p r^2(v_i, x_k) / p.$$

- Y 组原始变量被 u_i 解释的方差比例为

$$n_{u_i} = \sum_{k=1}^q r^2(u_i, y_k) / q.$$

- Y 组原始变量被 v_i 解释的方差比例为

$$n_{v_i} = \sum_{k=1}^q r^2(v_i, y_k)/q.$$

典型相关分析法的基本思路

- 假设有两组随机变量 $X = (x_1, x_2, \dots, x_p)^T, Y = (y_1, y_2, \dots, y_q)^T, C$ 为 $p + q$ 组总体的 n 次标准化数据阵, 有

$$\begin{pmatrix} a_{11} & \cdots & a_{1p} & b_{11} & \cdots & b_{1q} \\ a_{21} & \cdots & a_{2p} & b_{21} & \cdots & b_{2q} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{np} & b_{n1} & \cdots & b_{nq} \end{pmatrix}$$

- 第一步, 计算相关系数矩阵 R , 并将 R 剖分为

$$R = \begin{pmatrix} R_{11} & R_{12} \\ R_{21} & R_{22} \end{pmatrix}$$

其中 R_{11} 和 R_{22} 分别为第一组变量和第二组变量的相关系数阵, $R_{12}=R_{21}^T$ 为第一组与第二组的相关系数阵。

- 第二步, 求典型相关系数及典型变量。首先求 $M_1 = R_{11}^{-1} R_{12} R_{22}^{-1} R_{21}$ 的特征值 λ_i^2 , 特征向量 $\rho^{(i)}$; $M_2 = R_{22}^{-1} R_{21} R_{11}^{-1} R_{12}$ 的特征值 λ_j^2 , 特征向量 $\gamma^{(j)}$ 则典型变量为

$$u_1 = \rho^{(1)T} X, v_1 = \gamma^{(1)T} Y, \dots, u_s = \rho^{(s)T} X, v_s = \gamma^{(s)T} Y, s = \min(p, q)$$

记 $U = (u_1, u_2, \dots, u_s)^T, V = (v_1, v_2, \dots, v_s)^T$

- 第三步, 典型相关系数 λ_i 的显著性检验
- 第四步, 典型结构与典型冗余分析

matlab代码

- `[R,A,B,U,V,stas]=canoncorr(x,y)`
 - R: 典型相关系数
 - A: x组变量的典型系数(用于计算x的典型变量 $U=X*A$)
 - B: y组变量的典型系数(用于计算y的典型变量 $V=Y*B$)
 - U,V: 分别为x和y的典型变量
 - stas: 包含显著性检验结果
 - 如果有需要, 需提前对x,y作标准化处理

对应分析

- 同一平面上对变量和样品一起进行分类, 从而揭示所研究的样品和变量间的内在联系
- 画出行列散点图, 根据远近关系分析联系程度, 包括同行、列和行列之间的关系。

- 计算过程

- 由原始数据矩阵 A 计算对应阵 P

$$P = \frac{1}{T}A = (p_{ij})_{n \times p}, T = \sum_{i=1}^n \sum_{j=1}^p a_{ij}$$

- 计算边缘分布

$$r = P1_p = \begin{pmatrix} p_{1\cdot} \\ \vdots \\ p_{n\cdot} \end{pmatrix}, c = P^T 1_n = \begin{pmatrix} p_{\cdot 1} \\ \vdots \\ p_{\cdot p} \end{pmatrix}$$

其中

$$p_{i\cdot} = \sum_{j=1}^p p_{ij}, p_{\cdot j} = \sum_{i=1}^n p_{ij}$$

- 对 P 中心化

$$S = P - rc$$

- 计算标准化矩阵 M

$$M = D_r^{-1/2} S D_c^{-1/2}$$

其中

$$D_r = \text{diag}\{p_{1\cdot}, p_{2\cdot}, \dots, p_{n\cdot}\}, D_c = \text{diag}\{p_{\cdot 1}, p_{\cdot 2}, \dots, p_{\cdot p}\}$$

- 对标准化矩阵 M 做奇异值分解

$$M = S \Sigma V^T$$

- 奇异值平方计算贡献率
- 计算行、列坐标

$$F = D_r^{-1/2} U \Sigma \text{ 行坐标}, G = D_c^{-1/2} V \Sigma \text{ 列坐标}$$

- 取行、列坐标的前两个(一般是前两个, 具体看贡献度)绘制散点图
- 分析散点图

多维标度法

- 已知有 n 个由多个指标反映的客体，但反映客体的指标个数、指标本身可能是模糊的，仅仅知道 n 个客体之间的某种距离(不一定是欧几里得距离),希望由这种距离或相似性信息出发，在较低维度的欧几里得空间中把这 n 个客体(作为几何点)的图形描绘出来，从而揭示这 n 个客体之间的结构关系
- 距离阵
 - 对于一个 $n \times n$ 的矩阵 $D = (d_{ij})$ 满足

$$\begin{cases} D^T = D \\ d_{ij} \geq 0, d_{ii} = 0, i, j = 1, 2, \dots, n \end{cases}$$

则称 D 为距离阵, d_{ij} 称为第 i 个点与第 j 个点之间的距离。

- 欧几里得距离阵
 - 对于一个 $n \times n$ 的距离阵 $D = (d_{ij})$ ，如果存在某个正整数 p 和 R^p 中的 n 个点 $e_1, e_2, \dots, e_n$ 使得

$$d_{ij}^2 = (e_i - e_j)^T (e_i - e_j), i, j = 1, 2, \dots, n,$$

则称 D 为欧几里得距离阵。

- 多维标度的经典解
 - 由距离阵构造矩阵 $A = (a_{ij} = (-\frac{1}{2}d_{ij}^2))$ 。
 - 作出矩阵 $B = HAH$,其中 $H = I_n - \frac{1}{n}E_n$ 。
 - 求出 B 的 k 个最大特征值 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k$ 和对应的正交特征值 $\alpha_1, \dots, \alpha_k$ ，并满足规格化条件 $\alpha_i^T \alpha_i = \lambda_i, i = 1, 2, \dots, k$
- 上述对于 k 的选取基于实现确定(如 $k=1,2,3$)或考虑前 k 个特征值在全体特征值中所占的比例,先将 λ_i 降序排列。如果 λ_i 均非负，则说明 B 为半正定矩阵， D 为欧几里得距离阵，依据

$$\varphi = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_n} \geq \varphi_0$$

确定上式成立最小的 k 值，其中 φ_0 是预给定的百分数.若 λ_i 中有负值，表明 D 不是欧几里得距离阵,这时用

$$\frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{|\lambda_1| + |\lambda_2| + \dots + |\lambda_n|} \geq \varphi_0$$

求出最小的 k 值,但必须要求 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k \geq 0$ ，否则必须减少 φ_0 的值以减少个数 k 。

- 将所求的特征向量顺序排成一个 $n \times k$ 矩阵 $\hat{X} = (\alpha_1, \alpha_2, \dots, \alpha_k)$ 则 $\hat{X}$ 就是 D 的一个拟合构图，或者说 $\hat{X}$ 的行向量 $e_i^T = (x_{i1}, x_{i2}, \dots, x_{ik}), i = 1, 2, \dots, n$ 对应点 $P_1, P_2, \dots, P_n$ 是 D 的拟合构图点。该 k 维拟合图称为经典解 k 维拟合构图(简称经典解)
- 相似阵情形
 - 有时已知的不是 n 个客体之间的某种距离，而是已知 n 个客体之间的某种相似性，即已知的是一个相似矩阵。

◦ 设 $C = (c_{ij})$ 为一个相似矩阵, 令

$$d_{ij} = (c_{ii} - 2c_{ij} + c_{jj})^{1/2}$$

得到一个距离矩阵 $D = (d_{ij})$, 称上述变换式为从相似阵 C 到距离矩阵 D 的标准变换。