

综合评价与决策方法

理想方法(TOPSIS法)

- 计算步骤

- 用向量规范化方法求得规范决策矩阵。设多属性决策问题的决策矩阵为 $A = (a_{ij})_{m \times n}$ ，规范化决策矩阵 $B = (b_{ij})_{m \times n}$ ，其中

$$b_{ij} = \frac{a_{ij}}{\sqrt{\sum_{i=1}^m a_{ij}^2}} \quad i = 1, 2, \dots, m; j = 1, 2, \dots, n$$

- 构造加权规范化矩阵 $C = (c_{ij})_{m \times n}$ 。设有决策人给定各属性的权重向量为 $w = (w_1, w_2, \dots, w_n)^T$ ，则

$$c_{ij} = w_j \cdot b_{ij}, i = 1, 2, \dots, m; j = 1, 2, \dots, n$$

- 确定正理想解 C^* 和负理想解 C^0 ，设正理想解 C^* 的第 j 个属性为 c_j^* ，负理想解 C^0 的第 j 个属性值为 c_j^0 ，则

$$\text{正理想解: } c_j^* = \begin{cases} \max_i c_{ij}, & j \text{ 为效益型属性} \\ \min_i c_{ij}, & j \text{ 为成本型属性} \end{cases}$$

$$\text{负理想解: } c_j^0 = \begin{cases} \min_i c_{ij}, & j \text{ 为效益型属性} \\ \max_i c_{ij}, & j \text{ 为成本型属性} \end{cases}$$

- 计算各方案到正理想解与负理想解的距离。备选方案 d_i 到正理想解的距离为

$$s_i^* = \sqrt{\sum_{j=1}^n (c_{ij} - c_j^*)^2}, i = 1, 2, \dots, m$$

备选方案 d_i 到负理想解的距离为

$$s_i^0 = \sqrt{\sum_{j=1}^n (c_{ij} - c_j^0)^2}, i = 1, 2, \dots, m$$

- 计算各方案的排序指标值(即综合评价指数),即

$$f_i^* = s_i^* / (s_i^0 + s_i^*), i = 1, 2, \dots, m$$

- 按 f_i^* 由大到小排列方案的优劣次序

- 针对实际问题首先进行数据预处理，关键在于属性规范化，常见属性规范化方法如下：

- 线性变换：原始决策矩阵为 $A = (a_{ij})_{m \times n}$, 变换后矩阵为 $B = (b_{ij})_{m \times n}$ 。设 a_j^{max} 为决策变量中第 j 行中的最大值, a_j^{min} 是决策变量矩阵第 j 列中的最小值。若 x_j 为效益型属性, 则

$$b_{ij} = a_{ij} / a_j^{max}$$

采用上式属性规范化时, 变换的最差属性值不易为0, 最优属性值为1
若 x_j 为成本属性, 则

$$b_{ij} = 1 - a_{ij} / a_j^{max}$$

采用上式进行属性规范时, 经过变换的最优属性值不一定为1, 最差属性值为0

- 标准0-1变换。为使每个属性最优值为1且最差值为0可以进行标准0-1变换, 对效益型属性 x_j 令

$$b_{ij} = \frac{a_{ij} - a_j^{min}}{a_j^{max} - a_j^{min}}$$

对成本型属性 x_j , 令

$$b_{ij} = \frac{a_j^{max} - a_{ij}}{a_j^{max} - a_j^{min}}$$

- 区间属性变换。有些属性既非效益属性, 又非成本型。设给定最优区间为 $[a_j^0, a_j^*]$, a_j' 无法容忍的下限, a_j'' 为无法容忍上限, 则

$$b_{ij} = \begin{cases} 1 - (a_j^0 - a_{ij}) / (a_j^0 - a_j'), & a_j' \leq a_{ij} \leq a_j^0, \\ 1, & a_j^0 \leq a_{ij} \leq a_j^*, \\ 1 - (a_{ij} - a_j^*) / (a_j'', -a_j^*), & a_j^* < a_{ij} \leq a_j'', \\ 0, & \text{其它.} \end{cases}$$

变换后的属性值 b_{ij} 与原属性值 a_{ij} 之间的函数图形为一般梯形。当属性值最优区间的上下限相等时, 最优区间退化为一个点时, 函数图形退化为三角形。

- 向量规范化: 无论成本型属性还是效益型属性, 向量规范化均用下式进行变换:

$$b_{ij} = \frac{a_{ij}}{\sqrt{\sum_{i=1}^m a_{ij}^2}} \quad i = 1, 2, \dots, m; j = 1, 2, \dots, n$$

- 标准化处理

$$b_{ij} = \frac{a_{ij} - \mu_j}{s_j}, \quad i = 1, 2, \dots, m, j = 1, 2, \dots, n.$$

其中

$$\mu_j = \frac{1}{m} \sum_{i=1}^m a_{ij}, s_j = \sqrt{\frac{1}{m-1} \sum_{i=1}^m (a_{ij} - \mu_j)^2}, j = 1, 2, \dots, n$$

模糊综合评判法

- 一维模糊综合评价法建立步骤(人事考核)

- 确定因素集：多种方面评价员工表现，包括工作绩效，工作态度，沟通能力等，这些因素构成评价指标体系集合，即因素集，记为

$$U = \{u_1, u_2, \dots, u_n\}$$

- 确定评语集：每个指标有不同评价值，形成不同等级，如好、较好、中等、较差、差、很差等。不同决断集合构成评语集，记为

$$V = \{v_1, v_2, \dots, v_m\}$$

- 确定各因素的权重：确定因素集中各个因素在综合评价中所起到的作用，是 U 上的一个模糊向量，记为

$$A = [a_1, a_2, \dots, a_n]$$

式中： a_i 为第 i 个因素的权重，且满足 $\sum_{i=1}^n a_i = 1$

- 确定模糊综合判断矩阵：对指标 u_i 来说，各个评语的隶属度为 V 上的模糊子集，对指标 u_i 的评价为

$$R_i = [r_{i1}, r_{i2}, \dots, r_{im}]$$

各指标模糊综合判断矩阵为

$$R = \begin{pmatrix} r_{11} & r_{12} & \cdots & r_{1m} \\ r_{21} & r_{22} & \cdots & r_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ r_{n1} & r_{n2} & \cdots & r_{nm} \end{pmatrix}$$

它是一个从 U 到 V 的模糊关系矩阵

- 综合评价：如果有一个从 U 到 V 的模糊关系 $R = (r_{ij})_{n \times m}$ ，那么利用 R 就可以得到一个模糊变换

$$T_R : F(U) \rightarrow F(V)$$

由此变换，就可以得到综合评判结果 $B = A \cdot R$ 综合后的评判可看作 V 上的模糊向量,记为 $B = [b_1, b_2, \dots, b_m]$

- 多层次模糊综合评判(人事考核)

- 当复杂系统涉及指标较多时，需要考虑的因素很多，仍使用一维模糊综合评判时会出现因素过多，权数分配难以确定和满足归一化条件时每个因素的权值都较小的问题。采用多层次模糊综合评判方法可以解决这种系统问题。二维模糊综合评判法模型建立步骤如下：

- 将因素集 $U = u_1, u_2, \dots, u_n$ 按某种属性分成 s 个子因素集 $U_1, U_2, \dots, U_s$, 其中 $U_i = u_{i1}, u_{i2}, \dots, u_{in_i}, i = 1, 2, \dots, s$, 且满足
 - $n_1 + n_2 + \dots + n_s = n$
 - $U_1 \cup U_2 \cup \dots \cup U_s = U$
 - 对任意的 $i \neq j$ 有 $U_i \cap U_j = \emptyset$
- 对每一个因素集 U_i 分别做出综合评判。设 $V = v_1, v_2, \dots, v_m$ 为评语集, U_i 中各因素相对于 V 的权重分配是

$$A_i = [a_{i1}, a_{i2}, \dots, a_{in_i}]$$

若 $\tilde{R}$ 为单因素评判矩阵, 则得到一级评判向量

$$B_i = A_i \cdot \tilde{R}_i = [b_{i1}, b_{i2}, \dots, b_{im}], i = 1, 2, \dots, s$$

- 将每个 U_i 看作一个因素, 记为

$$K = \{\tilde{u}_1, \tilde{u}_2, \dots, \tilde{u}_s\}$$

这样 K 又是一个单因素集, K 的单因素评判矩阵为

$$R = \begin{pmatrix} B_1 \\ B_2 \\ \vdots \\ B_s \end{pmatrix} = \begin{pmatrix} b_{11} & b_{12} & \cdots & b_{1m} \\ b_{21} & b_{22} & \cdots & b_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ b_{s1} & b_{s2} & \cdots & b_{sm} \end{pmatrix}$$

每个 U_i 作为 U 的一部分, 反映 U 的某种属性, 按照他们的重要性给出权重分配 $A = [a_1, a_2, \dots, a_s]$, 于是得到二级评判向量

$$B = A \cdot R = [b_1, b_2, \dots, b_m]$$

如果每个子因素集 $U_i (i = 1, 2, \dots, s)$ 含有较多的因素, 则可以将 U_i 再进行划分, 于是有三级、四级甚至五级评判模型

数据包络分析(分析多指标输入和多指标输出系统)

- 相对有效评价: C^2R 模型
- 设有 m 个评价对象, 每个评价对象有 n 种投入和 s 种产出, 设 $a_{ij} (i = 1, 2, \dots, m, j = 1, 2, \dots, n)$ 表示第 i 个评价对象的第 j 种投入量, $b_{ik} (i = 1, 2, \dots, m, k = 1, 2, \dots, s)$ 表示第 i 个评价对象的第 k 种产出量, $u_j (j = 1, 2, \dots, n)$ 表示第 j 种投入的权值, $v_k (k = 1, 2, \dots, s)$ 表示第 k 种产出的权值
- 向量 $\alpha_i, \beta_i (i = 1, 2, \dots, m)$ 分别表示评价对象 i 的输入和输出向量, u 和 v 分别表示输入、输出权值向量, 则 $\alpha_i = [a_{i1}, a_{i2}, \dots, a_{in}]^T$, $\beta_i = [b_{i1}, b_{i2}, \dots, b_{is}]^T$, $u = [u_1, u_2, \dots, u_n]^T$, $v = [v_1, v_2, \dots, v_s]^T$
- 定义评价对象 i 的效率评价指数为

$$h_i = (\beta_i^T v) / (\alpha_i^T u), i = 1, 2, \dots, m$$

评价对象 i_0 的效率的数学模型为

$$\begin{aligned} & \max \frac{\beta_{i_0}^T v}{\alpha_{i_0}^T u}, \\ & s.t. \begin{cases} \frac{\beta_i^T v}{\alpha_i^T u} \leq 1, i = 1, 2, \dots, m, \\ u \geq 0, v \geq 0, u \neq 0, v \neq 0. \end{cases} \end{aligned}$$

通过Charnes-Cooper变换: $\omega = tu, \mu = tv, t = \frac{1}{\alpha_{i_0}^T u}$ 可以将模型变换为等价的线性规划模型问题

$$\begin{aligned} & \max V_{i_0} = \beta_{i_0}^T \mu \\ & s.t. \begin{cases} \alpha_i^T \omega - \beta_i^T \mu \geq 0, i = 1, 2, \dots, m, \\ \alpha_{i_0}^T \omega = 1, \\ \omega \geq 0, \mu \geq 0 \end{cases} \end{aligned}$$

- 可以证明这两个模型是等价的，对于 C^2R 模型有如下定义
 - 若线性规划问题的最优目标值 $V_{i_0} = 1$ 则称评价对象 i_0 是弱DEA有效的
 - 若线性规划问题存在最优解 $\omega^* > 0, \mu^* > 0$ ，并且其最优目标值 $V_{i_0} = 1$ ，则成评价对象 i_0 是DEA有效的
- 以上定义表明所谓DEA有效，就是指哪些评价对象，他们的投入产出比达到最大，因此可以用DEA方法来对评价对象进行评价。

灰色关联分析法

- 具体步骤
 - 确定比较数列和参考数列。设评价对象有 m 个，评价指标变量有 n 个，每个指标变量 $x_j (j = 1, 2, \dots, n)$ 都是效益型指标变量。比较数列为

$$a_j = \{a_i(j) | j = 1, 2, \dots, n\}, \quad i = 1, 2, \dots, m,$$

式中 $a_i(j)$ 是第 i 个评价对象关于第 j 个指标变量 x_j 的取值.参考数列为 $a_0 = \{a_0(j) | j = 1, 2, \dots, n\}$ ，一般取 $a_0(j) = \max_{1 \leq i \leq m} \{a_i(j)\}$ ，即参考数列相当于一个虚拟的最好评价对象的各项指标值。

- 确定各指标对应的权重。 $w = (w_1, w_2, \dots, w_n)$ ，其中 $w_j, j = 1, 2, \dots, n$ 为第 j 个评价指标对应的权重。
- 计算灰色关联系数

$$\zeta_i(j) = \frac{\min_{1 \leq i \leq m} \max_{1 \leq t \leq n} |a_0(t) - a_s(t)| + \rho \max_{1 \leq s \leq m} \max_{1 \leq t \leq n} |a_0(t) - a_s(t)|}{|a_0(j) - a_i(j)| + \rho \max_{1 \leq s \leq m} \max_{1 \leq t \leq n} |a_0(t) - a_s(t)|}, \quad i = 1, 2, \dots, m, j = 1, 2, \dots, n$$

$\zeta_i(j)$ 为比较数列 a_i 对参考数列 a_0 在第 j 个指标上的关联系数，其中 $\rho \in [0, 1]$ 为分辨系数，

$\min_{1 \leq i \leq m} \max_{1 \leq t \leq n} |a_0(t) - a_s(t)|$ 、 $\max_{1 \leq s \leq m} \max_{1 \leq t \leq n} |a_0(t) - a_s(t)|$ 分别称为两级最小差及两级最大差；一般而言，分辨系数 ρ 越大，分辨率越大； ρ 越小，分辨率越小。

- 计算灰色加权关联度。灰色加权关联度的计算公式为

$$r_i = \sum_{k=1}^n w_k \zeta_i(k)$$

式中 r_i 为第 i 个评价对象对理想对象的灰色加权关联度，若没有给出各指标变量的权重，则各指标变量取相等的权重，即 $w_j=1/n, j=1, 2, \dots, n$

- 评价分析。根据灰色加权关联度的大小，对各评价对象进行排序，可建立评价对象的关联序，关联度越大，其评价结果越好。

主成分分析法

• 计算过程

- 对原始数据进行标准化处理，将各项指标 a_{ij} 转化成标准化指标 $\tilde{a}_{ij}$
- 计算相关系数矩阵 $R = (r_{ij})_{n \times n}$
- 计算相关系数矩阵 R 的特征值和特征向量，特征值 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ ，及对应的标准化特征向量 $u_1, u_2, \dots, u_n$ ，其中 $u_j = (u_{j1}, u_{j2}, \dots, u_{jn})^T$ ，由特征向量组成新的指标变量 $Y = U * X$
- 选择 p 个主成分，计算综合评价
 - 计算特征值 λ_i 的信息贡献率 b_i 和累计贡献率 α_p

$$b_i = \frac{\lambda_i}{\sum_{k=1}^n \lambda_k}, i = 1, 2, \dots, n$$

为主成分 y_i 的信息贡献率

$$\alpha_p = \frac{\sum_{k=1}^p \lambda_k}{\sum_{k=1}^n \lambda_k}$$

为主成分 $y_1, y_2, \dots, y_p$ 的累计贡献率，当 α_p 接近1时(0.85, 0.9, 0.95)，选取前 p 个指标变量 $y_1, y_2, \dots, y_p$ 作为 p 个主成分，代替原来 n 个指标变量，从而可对 p 个主成分进行综合评价

- 计算综合得分

$$Z = \sum_{j=1}^p b_j y_j$$

式中 b_j 为第 j 个主成分的信息贡献率，根据综合得分值就可以进行评价。

秩和比综合评价法

- 原理：秩和比(Rank Sum Ration, RSR)综合评价法原理是在一个 n 行 m 列的矩阵中通过秩转换，获得无量纲统计量RSR;以RSR值为对象的优劣直接排序或分档排序，从而对评价对象做出综合评价

- 样本秩概念：设 $x_1, x_2, \dots, x_n$ 是一元总体抽取的容量为 n 的样本，从小到大顺序的统计量为 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ 。若 $x_i = x_{(k)}$ ，则称 k 是 x_i 在样本中的秩，记作 R_i ，对每一个 $i = 1, 2, \dots, n$ ，称 R_i 是第 i 个统计量。 $R_1, R_2, \dots, R_n$ 总称为统计量。
- 秩和比综合评价法步骤：
 - 编秩。将 n 个评价对象的 m 个评价指标排列成 n 行 m 列的原始数据表。编出每个指标的评价对象秩，其中效益型指标从小到大编秩，成本型指标从大到小编秩，同一指标数据相同者编平均秩。得到秩矩阵记为 $R = (R_{ij})_{n \times m}$
 - 计算秩和比(RSR)。根据公式

$$RSR_i = \frac{1}{mn} \sum_{j=1}^m R_{ij}, i = 1, 2, \dots, n$$

计算秩和比。当各评价指标的权重不同时，计算加权秩和比(WRSR)，计算公式为

$$WRSR_i = \frac{1}{n} \sum_{j=1}^m w_j R_{ij}, i = 1, 2, \dots, n$$

式中 w_j 为第 j 个评价指标的权重， $\sum_{j=1}^m w_j = 1$

- 分档排序。根据RSR或WRSR的值对评价对象进行分档排序，RSR或WRSR值越大，其评价越好

基于熵权法的评价方法

- 根据熵的定义与原理，当系统可能处于集中不同的状态，每种状态出现的概率为 $p_i (i = 1, 2, \dots, m)$ ，则该系统的熵可定义为

$$e_i = -\frac{1}{\ln m} \sum_{i=1}^m p_i \ln p_i$$

熵权法是一种客观的赋权方法。具体使用过程中，熵权法根据各指标的变异程度，利用信息熵计算出各指标的熵权，从而得出较为客观的指标权重。

- 计算步骤：
 - 利用原始数据矩阵 $A = (a_{ij})_{n \times m}$ 计算 $p_{ij} (i = 1, 2, \dots, n, j = 1, 2, \dots, m)$ ，即第 i 个评价对象关于第 j 个指标值的比重：

$$p_{ij} = \frac{a_{ij}}{\sum_{i=1}^n a_{ij}}, i = 1, 2, \dots, n, j = 1, 2, \dots, m$$

- 计算第 j 指项指标的熵值

$$e_j = -\frac{1}{\ln n} \sum_{i=1}^n p_{ij} \ln p_{ij}, j = 1, 2, \dots, m$$

- 计算第 j 项指标的变异系数:

$$g_j = 1 - e_j, j = 1, 2, \dots, m$$

由此可见对指标 j , e_j 越大, 指标值的变异程度就越小

- 计算第 j 项指标的权重:

$$w_j = \frac{g_j}{\sum_{j=1}^m g_j}, j = 1, 2, \dots, m$$

- 计算第 i 个评价对象的综合评价值:

$$s_i = \sum_{j=1}^m w_j p_{ij}$$

PageRank算法

- 简化为在综合评价与决策方面的应用
- 对于一张有向图, 每个网页是一个顶点, 网页间的超链接是图的一个边, 邻接矩阵 $B = (b_{ij})_{N \times N}$, N 为顶点数, 如果从网页 i 到 j 有超链接, 则 $b_{ij} = 1$, 否则为0

记矩阵 B 的行和为

$$r_i = \sum_{j=1}^N b_{ij}$$

表示页面 i 出发的链接数目

定义矩阵 $A = (a_{ij})_{N \times N}$ 如下

$$a_{ij} = \frac{1-d}{N} + d \frac{b_{ij}}{r_i}, i, j = 1, 2, \dots, N$$

式子中 d 是参数模型, 通常取 $d = 0.85$, A 是马尔科夫链的转移概率矩阵; a_{ij} 表示从页面 i 转移到页面 j 的概率。由马尔科夫随机链的基本性质, 对于正则马尔可夫随机链存在平稳分布 $x = (x_1, x_2, \dots, x_N)^T$ 满足

$$A^T x = x, \sum_{i=1}^N x_i = 1$$

式中 x 表示在极限状态(转移次数趋于无限)下各网页被访问的概率分布, 定义为各个网页的PageRank值

$$x_k = \sum_{i=1}^N a_{ik} x_i = \frac{1-d}{N} + d \sum_{i: b_{ik}=1} \frac{x_i}{r_i}$$

网页 i 的PageRank值是 x_i ，它链接出的页面有 r_i 个，于是页面 i 将它的PageRank值分为 r_i 份，分别投票给它链接出的网页。 x_k 为网页 k 的PageRank值。

根据马尔科夫链的基本性质可以得到平稳分布(PageRank值)是转移概率矩阵 A 的转置矩阵 A^T 的最大特征值所对应的归一化特征向量。